

ΕΡΓΑΣΙΑ ΕΞΑΜΗΝΟΥ

Πολυτροπική Ανάλυση Μουσικών Δεδομένων

Multimodal Music Analysis

Μάθημα: Τεχνικές Εξόρυξης Δεδομένων

Γλώσσα Υλοποίησης: Python (pandas, scikit-learn, numpy, matplotlib/seaborn, gensim/transformers)

Παραδοτέα: Ένα (1) Jupyter Notebook (.ipynb) ανά μέρος, πλήρως τεκμηριωμένο.



ΟΜΑΔΙΚΗ ΕΡΓΑΣΙΑ (έως 2 άτομα)

Ατομικές υποβολές δεν θα γίνουν δεκτές.

Περιγραφή

Στόχος της εργασίας είναι η ανάπτυξη ενός ολοκληρωμένου pipeline εξόρυξης γνώσης από μουσικά δεδομένα, συνδυάζοντας δύο διαφορετικές πηγές πληροφορίας (modalities): **Ήχο** (Audio) και **Κείμενο** (Στίχοι/Lyrics). Θα κληθείτε να εφαρμόσετε τεχνικές

- προεπεξεργασίας
- εξαγωγής χαρακτηριστικών μέσω Embeddings
- οπτικοποίησης δεδομένων
- κατηγοριοποίησης
- αξιολόγησης μοντέλων

Το dataset περιλαμβάνει:

1. **Audio features/Metadata:** (π.χ. έτοιμα low-level features).
2. **Lyrics:** Το κείμενο των στίχων.
3. **Labels:** Η κατηγορία (Genre) ή/και το συναίσθημα (Sentiment/Valence).
4. **Tags:** Τα tags (User Generated Content) δίνουν την "ανθρώπινη" ερμηνεία του τραγουδιού



ΜΕΡΟΣ Α: Προεπεξεργασία, Embeddings και Εξερευνητική Ανάλυση

Παράδοση: 19/04/2026

Στόχος: Η μετατροπή των δεδομένων σε κατάλληλες διανυσματικές αναπαραστάσεις (Embeddings) και η μελέτη τους μέσω οπτικοποιήσεων.

1. Συλλογή Δεδομένων (Data collection)

Σας δίνονται 5 αρχεία στο eclass. Το πρώτο βήμα είναι να τα “συνδέσετε”. Χρησιμοποιήστε την βιβλιοθήκη pandas για να φορτώσετε τα αρχεία και εξετάστε τη δομή τους. Το πεδίο-κλειδί για τη σύνδεση είναι το id (**Song ID**).

- **Filtering:** Επιλέξτε μόνο τα τραγούδια που ανήκουν στα 5 πιο συχνά μουσικά είδη (Top-5 Genres) όπως προκύπτουν από το id_genres.csv. Αγνοήστε όλα τα υπόλοιπα. (Σημ. Μπορείτε όμως και να χρησιμοποιήσετε genres της δικής σας επιλογής).
- **Intersection:** Κρατήστε μόνο τα τραγούδια για τα οποία έχετε δεδομένα και στα 3 αρχεία (Audio Stats, Lyrics, Genre).
- **Αποτέλεσμα:** Ένα καθαρό pandas DataFrame (ή CSV) που περιέχει μόνο τα τελικά τραγούδια (π.χ. 5.000 - 10.000 εγγραφές) με στήλες: id, genre, lyrics, mfcc_stats.

***Tip: Διαχείριση Μεγάλων Αρχείων:** Η τεχνική που ψάχνετε είναι η χρήση του **chunksize** στην `pd.read_csv`. Αυτό επιτρέπει να διαβάσετε ένα αρχείο τμηματικά (π.χ. ανά 500 γραμμές), να φιλτράρετε/επεξεργάζεστε κάθε κομμάτι, και να κρατάτε στη μνήμη μόνο ότι επιθυμείτε κάθε φορά. Επίσης, μπορείτε να διαβάσετε συμπιεσμένα αρχεία `.tar.gz` ή `.zip` απευθείας μέσω Python, να κάνετε `iterate` τα περιεχόμενα, και να εξάγετε το `text` μόνο αν το όνομα του αρχείου ταιριάζει με κάποιο ID από τη λίστα στόχο.*

2. Εξαγωγή Χαρακτηριστικών & Embeddings (Feature Extraction)

Απαιτείται η δημιουργία δύο ξεχωριστών πινάκων χαρακτηριστικών:

- **Text Embeddings:**
 - **Word Embeddings:** Εκπαιδεύστε ένα μοντέλο **Word2Vec** ή **Doc2Vec** (χρησιμοποιώντας τη βιβλιοθήκη `gensim`) πάνω στο corpus των στίχων σας.
 - **Εναλλακτικά/Bonus:** Χρησιμοποιήστε προ-εκπαιδευμένα embeddings (π.χ. GloVe ή BERT-based sentence transformers) για να εξάγετε ένα πυκνό διάνυσμα (dense vector) για κάθε τραγούδι (π.χ. μέσος όρος των word vectors ή CLS

token).

- **Audio Embeddings:**

- Για τον ήχο, σας δίνονται υψηλής διάστασης στατιστικά χαρακτηριστικά MFCC (Mean & Covariance matrix flattened). Αυτά τα διανύσματα είναι πολύ μεγάλα και θορυβώδη. Ζητούμενο: Δημιουργήστε συμπαγή **Audio Embeddings** εφαρμόζοντας τεχνικές Learning/Reduction:
 - **PCA:** Κρατήστε το 95% της διακύμανσης.
 - (Bonus) **Autoencoder:** Εκπαιδεύστε ένα απλό νευρωνικό δίκτυο (Dense Autoencoder με Keras/sklearn) που να συμπιέζει τα MFCC stats σε ένα bottleneck layer (π.χ. 32 διαστάσεις). Αυτό το compressed vector θα είναι το 'Audio Embedding' σας

3. Οπτικοποίηση και Ανάλυση (Exploratory Data Analysis - EDA)

- **Word Clouds ανά Genre:** Επιλέξτε τα 2 πιο διαφορετικά μεταξύ τους είδη (π.χ. Metal και Pop). Για το καθένα, συγκεντρώστε όλα τα tags των τραγουδιών του και δημιουργήστε ένα Word Cloud.
- **Bar Chart:** Ποια είναι τα 10 πιο συχνά tags ανά είδος (genre) ;
- **Dimensionality Reduction:** Εφαρμόστε **PCA** ή **t-SNE** στα Text Embeddings και στα Audio Embeddings ξεχωριστά για να μειώσετε τις διαστάσεις σε 2D.
 - **Plots:**
 - Δημιουργήστε 2D Scatter plots των τραγουδιών, χρωματισμένα με βάση την κατηγορία (Genre). Παρατηρήστε αν σχηματίζονται συστάδες (clusters).
 - Συγκρίνετε οπτικά: Ποιο modality (Audio ή Text) φαίνεται να διαχωρίζει καλύτερα τις κλάσεις;
 - Μερικές φορές είναι δύσκολο να κατατάξουμε ένα τραγούδι σε ένα είδος μουσικής. Κάποιες φορές, είναι εύκολο να καταλάβουμε ότι πρόκειται για κλασσική μουσική ή rock κ.ο.κ. ενώ άλλες, τραγούδια πάλλονται μεταξύ ειδών και δεν μπορούμε εύκολα να αποφανθούμε σε τι είδος μουσικής κατατάσσονται. Να φτιάξετε κατάλληλο διάγραμμα που να δείχνει ακριβώς αυτό: Πόσα τραγούδια παρουσιάζουν ποικιλία ως προς το είδος μουσικής (genre) που ανήκουν. Δηλαδή, πόσα τραγούδια ανήκουν μόνο σε ένα είδος μουσικής, πόσα σε 2, ..., πόσα σε πάνω από 10 κ.ο.κ.
 - Να γίνει και το αντίστροφο. Πρώτα να βρεθούν τα top_n (για παράδειγμα 10) είδη μουσικής και έπειτα, να δείξετε πόσα τραγούδια κατατάσσονται στο καθένα από αυτά τα κορυφαία είδη;
 - Κάποια τραγούδια είναι γεμάτα στίχους ενώ άλλα έχουν ελάχιστους, αν έχουν. Να αναδείξετε την κατανομή αυτή για κάθε τραγούδι, τι μέγεθος έχουν οι στίχοι σε πλήθος λέξεων και σε πλήθος χαρακτήρων. Αν αφαιρέσουμε stopwords πόσες meaningful λέξεις έχουν πλέον τα τραγούδια;

- Θα περίμενε κανείς τα pop τραγούδια να είναι πιο χαρούμενα ενώ τα rock πιο στενάχωρα, γεμάτα θυμό ίσως. Με βάση το συναίσθημα (χρήση pre-trained VADER sentiment analysis tool) των στίχων και του αντίστοιχου είδους, να δείξετε κατά πόσο επιβεβαιώνεται αυτή η υπόθεση.
- **Similarity Analysis:** Υλοποιήστε κώδικα που, δοθέντος ενός τραγουδιού, βρίσκει τα 5 πιο "όμοια" τραγούδια βάσει συνημιτονοειδούς ομοιότητας (Cosine Similarity), πρώτα με βάση τους στίχους και μετά με βάση τον ήχο. Σχολιάστε τις διαφορές στα αποτελέσματα.



ΜΕΡΟΣ Β: Κατηγοριοποίηση, Fusion και Αξιολόγηση

Παράδοση: 31/05/2026

Στόχος: Η ανάπτυξη μοντέλων μηχανικής μάθησης για την πρόβλεψη της κατηγορίας/συναίσθηματος και η συγκριτική αξιολόγηση της συνεισφοράς του ήχου και του κειμένου.

1. Classification Models (Unimodal)

Εκπαιδεύστε 2 ταξινομητές της επιλογής σας (π.χ. SVM, Random Forest, k-NN κτλ) για το πρόβλημα του **Genre Classification**:

- **Model A (Text-only):** Χρησιμοποιεί ως είσοδο μόνο τα Text Embeddings.
- **Model B (Audio-only):** Χρησιμοποιεί ως είσοδο μόνο τα Audio Embeddings.

2. Multimodal Fusion (Συνδυασμός)

Υλοποιήστε και τις δύο παρακάτω στρατηγικές (δεν θα βρείτε έτοιμη συνάρτηση "fusion" στο sklearn, πρέπει να διαχειριστείτε τους πίνακες **numpy**):

- **Early Fusion:** Συνένωση (Concatenation) των διανυσμάτων Audio και Text σε ένα ενιαίο διάνυσμα **πριν** την εκπαίδευση του μοντέλου. Εκπαιδεύστε ένα **Model C (Fused)**.
- **Late Fusion:** Χρησιμοποιήστε τις πιθανότητες εξόδου (prediction probabilities) των Model A και Model B. Συνδυάστε τις (π.χ. μέσος όρος πιθανοτήτων ή soft voting) για να βγάλετε την τελική απόφαση.

3. Πειραματική Διαδικασία & Αξιολόγηση (Evaluation)

- **Cross-Validation:** Χρησιμοποιήστε 10-fold Cross-Validation για όλα τα πειράματα.

- **Metrics:** Καταγράψτε Accuracy, Precision, Recall, F1-score (Macro-averaged).
- **Confusion Matrices:** Δημιουργήστε τους πίνακες για τα Model A, B και C.
- **Σύγκριση:**
 - Δημιουργήστε ένα συγκεντρωτικό γράφημα (Bar chart) που συγκρίνει το F1-score των τριών προσεγγίσεων (Audio vs Text vs Combined).
 - Απαντήστε τεκμηριωμένα: Βοήθησε ο συνδυασμός των δεδομένων; Υπάρχουν κατηγορίες που προβλέπονται καλύτερα από το κείμενο και άλλες από τον ήχο;

4. Clustering (Unsupervised Learning)

Εφαρμόστε τον αλγόριθμο **K-Means** στο συνδυαστικό (Fused) διάνυσμα. Χρησιμοποιήστε μετρικές όπως το **Silhouette Score** για να βρείτε τον βέλτιστο αριθμό clusters. Συγκρίνετε τα clusters που προέκυψαν με τα πραγματικά labels χρησιμοποιώντας το Adjusted Rand Index (ARI).

Οδηγίες για το παραδοτέο

Η εργασία είναι ομαδική και μπορεί να εκπονηθεί σε ομάδες **έως 2 ατόμων**.

- Θα ανεβάσετε στο **eclass** ένα φάκελο της μορφής sdixxxx.zip (όπου sdi το AM ενός εκ των ατόμων της ομάδας) ο οποίος θα περιέχει μόνο τον κώδικά σας σε μορφή **python notebook** (προσοχή: δεν χρειάζεται να ανεβάσετε και τα αρχεία που θα επεξεργαστείτε). Το ίδιο μέλος που έκανε την υποβολή στο Α μέρος της εργασίας θα κάνει και την υποβολή στο β μέρος της εργασίας.
 - Το notebook πρέπει στην αρχή να περιέχει **τα ονόματα και τους AM** των μελών της ομάδας (το πλήρες όνομα σας στα ελληνικά!).
 - Το notebook πρέπει να έχει **“τρέξει”** ώστε να φαίνονται τα αποτελέσματα της εργασίας σας και όλες οι οπτικοποιήσεις. Το notebook αποτελεί και την ολοκληρωμένη αναφορά για την εργασία σας (δεν θα παραδώσετε τίποτα σε doc, pdf) , σχεδιάστε το με προσοχή, να θυμάστε να γράφετε ποιο ερώτημα απαντάται σε κάθε κελί.
 - Διευκρινίσεις για την εργασία θα δίνονται μέσω του e-class.
 - Εργασίες που δεν έχουν “τρέξει” δεν μπορούν να βαθμολογηθούν.
 - Εργασίες **δεν γίνονται δεκτές με email**, φροντίστε να είστε συνεπείς στην υποβολή της εργασίας σας.
-

Κριτήρια Αξιολόγησης Εργασίας

1. **Ορθότητα (40%):** Σωστή χρήση βιβλιοθηκών, απουσία bugs, σωστή υλοποίηση του fusion και του cross-validation.
 2. **Ανάλυση & Σχολιασμός (30%):** Η ποιότητα των Markdown cells στο Notebook. Δεν αρκεί να τρέχει ο κώδικας· πρέπει να εξηγείτε *τι* βλέπουμε στα διαγράμματα και *γιατί* συμβαίνει (π.χ. "Τα embeddings του κειμένου διαχωρίζουν καλύτερα το Rap από την Pop γιατί...").
 3. **Ποιότητα Γραφημάτων (20%):** Ευανάγνωστα διαγράμματα, με σωστούς άξονες, τίτλους και legends.
 4. **Δυσκολία/Πρωτοτυπία (10%):** Bonus για χρήση advanced embeddings (BERT/Transformers) ή advanced fusion techniques.
-

Χρήσιμοι σύνδεσμοι

<https://anasdrak.sites.aueb.gr/index.php/python-ai-scikit-learn/>

<https://huggingface.co/sentence-transformers/stsb-bert-base>


<https://huggingface.co/learn>

<https://www.kaggle.com/learn/pandas>

https://pandas.pydata.org/docs/user_guide/10min.html

Τα δεδομένα για την εργασία είναι από το παρακάτω σύνδεσμο

<https://zenodo.org/records/15394646>



ΚΑΛΗ ΕΠΙΤΥΧΙΑ!

